

## 一、研究動機

現有的階層式 Vision Transformer (ViT) 可解釋性分析 (如基於 KMeans 的 Token 分群法)，成功展現了 (ViT) 模型保留空間關係的階乘式處理模式。然而，目前的研究存在兩大限制：

1. **空間位置綁定限制**：現有特徵收集高度依賴「固定物理位置」切 patch 進行分群。一旦目標物件在圖像中發生平移、縮放或背景複雜化，相同語意特徵 (如人脸器官、物件部件) 將因物理位置偏移而被拆散，無法實現泛化。
2. **定性分析的主觀性**：對於「不同 Attention Head 捕捉不同語意特徵」 (例如：Head 4 抓鼻子、Head 6 抓嘴巴) 的關鍵結論，目前完全依賴研究者「肉眼觀察」與主觀「硬解釋」，在學術嚴謹度上缺乏數學與統計學上的客觀公信力。

## 二、研究目標

1. 導入「物件空間對齊 (Object Alignment)」機制，破除網格物理位置對 Token 提取的限制，實現跨影像的通用語意分群。
2. 建立一套「Attention Head 與分群結果的量化統計評估方案」，用數據和統計指標驗證 Attention Head 的特徵獨立性與語意相關性，將主觀定性觀察升級為科學定量驗證。

## 三、具體提案作法

### 1. 物件空間對齊 (Object Alignment) 可能作法

為了確保 KMeans 提取的 Token 具有「語意對齊」的前提，設計以下四種對齊路徑進行實驗與對比：

- **作法一：傳統影像幾何與邊緣對齊 (CV-based Alignment)**
  - 使用 Canny 邊緣偵測或主動輪廓模型 (Active Contour) 抓取圖像主體輪廓。
  - 計算物件的質心 (Centroid) 與主軸方向，透過仿射轉換 (Affine



果的一致性，驗證 Multi-Head Attention 是否真的發揮了「多視角」的作用。


- 判定邏輯：若不同 Head 的分群結果計算出的 ARI/NMI 顯著偏低（接近 0），即在數學上證明了「不同 Attention Head 確實捕捉了統計上高度獨立且相異的特徵空間」，證實多頭機制的互補性。

### • 方法三：Head與Cluster之語意相關性卡方檢定 (Chi-Square Test & Cramer's V)

- 在具備局部標籤（例如人臉器官標籤：眼、鼻、口）的子資料集上，將 KMeans 的「分群 ID」與「真實語意標籤」建立交叉表格。
- 進行卡方獨立性檢定並計算 Cramer's V 相關係數。若  $p\text{-value} < 0.05$  且 Cramer's V 顯著高，則量化證明「特定 Head 的特定 Cluster 與特定語意概念（如鼻子）存在極強的統計關聯性」。

### • 方法四：VLM 語意一致性量化 (VLM Semantic Consistency)

- 將同一個 KMeans Cluster 的代表影像組輸入 VLM（如 GPT-4）生成文字描述，並轉化為高維語意嵌入向量 (Text Embedding)。
- 計算同群內 (Intra-cluster) 與跨群間 (Inter-cluster) 語意向量的餘弦相似度 (Cosine Similarity)，以語意空間的距離量化評估分群的一致性。



人眼是跳來跳去 每秒XX下

位置偏移的問題

縮放大小問題

投到latent的距離分析要怎麼樣可以更全面