本次訓練的圖片處理流程

同一張來源圖分成學生與教師兩條路徑；僅物件縮放與平移，背景不跟著變換。

學生路徑 | 生成兩個完整畫布 view

① 原圖＋標註



橘框：annotation bbox
青線：物件輪廓

② 輪廓轉遮罩



填滿輪廓得到 alpha mask
依 mask 外框裁切物件

③ 物件 RGB × alpha



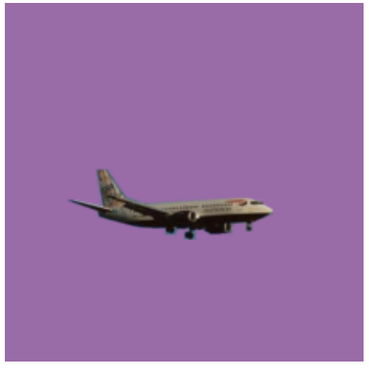
先乘 alpha，再分別 resize
格紋只表示此處的背景被移除

④ View A：224 × 224



物件長邊 64 px
位移 (-13, -10) px

④ View B：224 × 224



物件長邊 128 px
位移 (-9, +14) px

訓練取樣：長邊 ∈ {64, 96, 128}；dx、dy 各在 −16⋯+16
兩個 view 各自取樣，但共用同一背景色與類別標籤

教師路徑 | 原始 bbox 的固定 CLIP 目標

⑤ 原始 bbox crop



直接從高解析原圖裁切
框內仍可能包含背景

⑥ 補正方形＋CLIP 前處理



等比例保留完整 bbox
實際教師輸入：224 × 224

凍結 CLIP ViT-B/32
只 encode image

512 維 L2 正規化向量
同時監督兩個學生 view

正規化：學生使用 ImageNet mean/std；教師使用 CLIP mean/std。上方 view 顯示正規化前的 RGB，背景色是成對固定、隨來源／epoch 改變。