圖片進入模型後：CLIP 只直接監督深層

主要實驗：第 3、4 層；學生全模型可訓練，CLIP 教師凍結。

雙 view

A、B 分別通過同一模型

Stage 1

Stage 2

Stage 3

Stage 4

分類 head
CE loss

Stage 1、2 無直接 CLIP loss
深層梯度仍會回傳淺層；淺層沒有凍結。

對應物件 region
8 × 8 mask 加權讀取

對應物件 region
8 × 8 mask 加權讀取

推論：完整圖片 → 分類
不需要 CLIP 教師

凍結 CLIP 教師向量

Linear → 512
L2 正規化

Linear → 512
L2 正規化

CLIP cosine loss：兩層 × 兩 view 平均
總損失 = CE + 0.2 × CLIP loss

消融對照
全四層 0.2／前兩層 0.2
後兩層 0.2／後兩層 0.1