

# 階層式 Vision Transformer 可解釋性研究

會議記錄／影音內容整理紀錄（影音長度：57 分 11 秒）

整理內容：全片架構大綱、核心重點摘要、第一階段（00:00 - 15:00）詳細逐字紀錄

## 一、全片內容結構大綱 (Agenda & Structure)

| 時間區間          | 核心主題       | 內容概述                                                                     |
|---------------|------------|--------------------------------------------------------------------------|
| 00:00 - 04:30 | 背景與研究動機    | 介紹 Swin Transformer 與 PVT 架構；探討階層式 ViT 移除 <b>[CLS]</b> token 對可解釋性造成的挑戰。 |
| 04:31 - 09:14 | 模型架構與空間推導  | 推導 Flexible Patch Merging 機制、邊界 Padding 補齊規則與 token 空間索引 mapping。        |
| 09:15 - 15:30 | 語意分析核心流程   | 提出 Position-wise 特徵收集與 K-means 分群法，並以 Representative Patch 視覺化特徵演化。      |
| 15:31 - 25:00 | 受限視野逆向推導   | 推導受限視野（Receptive Field）反推公式；展示 token 如何還原映射至原始影像空間。                      |
| 25:01 - 38:00 | 實驗設計與特徵轉移  | CIFAR 與 ImageNet 子集實驗評估；探討淺層（紋理、邊緣）到深層（語意組件）的特徵演進。                       |
| 38:01 - 48:30 | 既有解釋性方法對比  | 與 Attention Rollout、Grad-CAM 及 CLIP-ViT 在定位性與語意豐富度上的對比與量化評估。             |
| 48:31 - 57:11 | 總結、限制與 Q&A | 彙整研究貢獻、運算時間複雜度限制以及未來的研究拓展方向。                                             |

## 二、技術要點與核心概念摘要 (Key Highlights)

### 1. 階層式架構帶來的可解釋性痛點

- 傳統 ViT 依賴單一的 **[CLS]** token 匯聚全圖注意力，常見方法如 **Attention Rollout** 便是透過反向連乘注意力矩陣來定位特徵。
- 階層式 ViT（Swin, PVT）為降低計算複雜度，移除了 **[CLS]** token 並在各 Stage 加入下採樣（Patch Merging），最終透過全域平均池化（GAP）輸出，造成現有注意力反推方法完全失效。
- Grad-CAM** 僅能產生目標類別的粗糙熱力圖，缺乏特徵組件層級的語意洞察力；而基於文字提示的 CLIP 衍生方法又受限於預先定義標籤。

## 2. 本研究之技術創新與方案

- **Flexible Patch Merging 與座標反推**：精確推導各 Stage 下採樣過程中的座標投影，即使在奇數尺寸邊界填充（Padding 向右與向下）情況下，依然能精確追蹤任意深層 token 對應到原始影像的受限視野（Receptive Field）。
- **Position-wise 特徵分群 (Clustering)**：收集同類別或跨樣本在相同空間座標的特徵向量集合  $F \in \mathbb{R}^{(M \times N, C)}$ ，透過 K-means 找出代表性向量與代表圖（Representative Patch）。
- **語意演化可視化**：直觀證明模型特徵從淺層的「低階紋理／顏色／邊緣」，逐漸聚合至深層的「具體結構／物件部件」，縮減了定位性與高階語意之間的 Semantic Gap。

## 三、語音逐字稿 (Transcript: 00:00 - 15:00)

### 00:00 - 01:12 開場準備與畫面切換

（投影片與視訊環境切換，確認簡報畫面正常投影片播放至螢幕中央）

### 01:13 - 02:05 階層式 ViT - Swin Transformer 架構介紹

首先介紹的是階層式 ViT，也就是 Swin Transformer。它主要提出了位移視窗注意力機制（Shifted Window based Self-Attention），將原本計算複雜度從原本的  $O(N^2)$  降低到與影像大小呈線性關係的  $O(N)$ 。

在架構上，它分成四個 Stage。各 Stage 之間利用 Patch Merging 進行下採樣，逐步縮減 token 的數量，藉此擴展特徵的維度。從圖中可以看到，輸入的影像經過 Patch Partition 後進入各個 Stage，並透過 Swin Transformer Block 做特徵提取與下採樣。

### 02:06 - 02:38 階層式 ViT - Pyramid Vision Transformer (PVT)

接著是 Pyramid Vision Transformer (PVT)。它同樣也是採用四個 Stage，每個 Stage 透過 Overlapping Patch Embedding 漸進式地縮減特徵圖的空間解析度。特徵圖的解析度從最開始的  $H/4 \times W/4$ ，逐步縮小至  $1/8$ 、 $1/16$  以及  $1/32$ 。此外，為了降低整體運算量，它引入了空間縮減注意力（Spatial Reduction Attention, SRA），在維持 Key 與 Value 空間縮減的同時，有效避免運算量暴增。

### 02:39 - 03:09 階層式 ViT 共通性與現有可解釋性瓶頸

比對這兩種階層式架構可以發現它們的共通性：第一，兩者都使用了 Patch Merging 機制（或是空間下採樣機制）來縮減 token 數量；第二，它們都省略了傳統 ViT 裡面的  $[CLS]$  token。

因為拿掉了  $[CLS]$  token，這使得以往針對 ViT 提出的可解釋性方法受到很大的限制。例如經典的 Attention Rollout，它高度依賴最後一層的  $[CLS]$  token 來追溯回全圖的注意力權重。缺乏  $[CLS]$  token，加上模型最後通常接全域平均池化（Global Average Pooling, GAP），使得傳統 Attention Rollout 無法直接套用在階層式 ViT 上。

### 03:10 - 03:35 現有可解釋性方法比對與侷限

如果看現有的可解釋性方法：

1. **基於注意力的方法（如 Attention Rollout）**：雖然運算速度快，但受限於必須依賴  $[CLS]$  token，且只能呈現熱力圖，無法提供更深層的語意概念。
2. **傳播／梯度反向方法（如 Grad-CAM）**：透過預測目標的梯度的加權，能提供類別特定的顯著性，但同樣只能畫出熱力圖，無法得知模型內部學到的具體特徵或組件語意。
3. **文字提示解譯方法（如 TextSpan、CLIP-ViT）**：能將文字與注意力結合，但受限於只能解讀預先定義好的文字標籤，彈性較低。

#### 03:36 - 04:30 研究動機與階層式可解釋架構設計

因此本研究的核心，是希望建立一套兼具「定位性（Localization）」與「語意理解（Understanding）」的分析方法，縮小兩者之間的語意落差（Semantic Gap）。

在模型設計上，我們提出階層式模型架構（Hierarchical Explainable-ViT）。模型接收大小為  $H \times W$  的圖片，先經過 Patch Embedding，接著進入數個 Stage。每個 Stage 內部包含複數個 Transformer Block，而在 Stage 與 Stage 之間，我們採用了 Flexible Patch Merging 機制，最後經由 GAP 與 Linear 層輸出分類結果。

#### 04:31 - 07:55 模型特徵與 Token 序列推導

（投影片切換至論文圖 3.2 詳細說明）如圖 3.2 所示，這張圖展示了模型各階層 token 序列的生成與追溯關係。每一層的 Stage 包含特徵提取、Patch Merging 與下採樣。

我們特別針對 Patch Merging 的過程做了詳細的數學定義與空間索引 mapping。傳統 Swin Transformer 的 Patch Merging 主要是以固定的  $2 \times 2$  鄰近 token 進行拼接，但本研究設計了更具彈性的組合模式，以便後續可以精確追蹤每一個 token 到底包含了原始影像中哪一塊區域的受限視野（Receptive Field）。

#### 07:56 - 09:14 Padding 機制與 Flexible Patch Merging

在 Patch Merging 過程中，若影像特徵圖的尺寸無法被合併的比例整除時，就必須進行 Padding 補齊。我們會向右與向下進行 padding。不同的 merge 組合會改變 token 的成長形狀（例如水平、垂直或對稱合併），進而影響語意分析時的空間特性。

#### 09:15 - 12:00 語意分析流程：Position-wise 特徵收集

接下來進入我們提出的語意分析流程核心。第一步是「Position-wise 特徵收集」。設計的出發點是：同一空間位置的特徵，通常在特定類別的資料集上會表現出一致性與穩定性。

因此我們將各資料集在相同位置的 token 特徵集合起來，形成特徵集合  $F \in \mathbb{R}^{(M \times N, C)}$ 。這樣做的好處是保留了空間位置資訊，能夠精確驗證該位置在各 Stage 是否呈現出特定且穩定的語意概念。

#### 12:01 - 14:20 空間特徵分群與 Representative Patch 選取

第二步是針對收集到的 token 向量進行 K-means 分群。在同一個空間位置下，我們將不同圖片在該位置所學到的特徵向量進行分群（K-means Clustering）。

分群後，每個 cluster 的中心點所代表的 token，我們會在資料庫中找到最接近該中心點的 patch，作為該

cluster 的「代表圖 (Representative Patch)」。藉由這些代表圖，我們就能直觀地觀察出：模型在該 Stage 的這個位置，究竟是在關注背景、邊緣、特定材質，還是高階的物件輪廓。

#### 14:21 - 15:00 Stage 特徵演化概念

從淺層 (Stage 0/1) 到深層 (Stage 2/3)，這些代表圖展現出明顯的階層變化。淺層多偏向顏色、低階邊緣與材質；而到了深層，則逐漸聚合成具體的語意物件部件 (如眼睛、鼻樑、邊界線條等)。